

Repositório:

https://github.com/Gustavo-Piccoli/Trabalho_Final_PLN

Análise de Emoções em Textos

Classificação de Granularidade Fina com Transformers

Processamento de Linguagem Natural e Recuperação de Informações

Gustavo Auad Piccoli · 00275858 Junho de 2026

Prof.^a Viviane Moreira · Prof. Dennis Giovani Balreira

Emoções vão além de positivo, negativo e neutro

Aplicações reais exigem granularidade e nuance emocional



Contexto

Assistentes virtuais, moderação de conteúdo e análise de feedback exigem compreensão emocional mais profunda que a polaridade.



Granularidade fina

27 emoções distintas — alegria, gratidão, raiva, medo, alívio — capturam nuances que apenas 3 classes perdem.



Multirrótulo

Um mesmo comentário pode expressar várias emoções ao mesmo tempo, como nas conversas reais do dia a dia.

A pergunta que guia o trabalho

Problema, motivação e hipótese de pesquisa

O desafio

- Emoções finas: 28 classes com forte desbalanceamento (muitas raras).
- Multirrótulo: cada texto pode ter várias emoções — decisão por limiar.
- Baseline do paper (BERT) tem F1 macro baixo nessa tarefa.

QUESTÃO DE PESQUISA

As melhorias de pré-treinamento do RoBERTa se traduzem em ganhos sobre o BERT nessa tarefa fina e multirrótulo?

Hipótese: sim — pré-treino mais robusto deve ajudar nas classes difíceis.

GoEmotions: 58 mil comentários, 28 classes

Um corpus grande, fino e naturalmente multirrótulo

58 mil

comentários do Reddit, rotulados por humanos

28

classes — 27 emoções + neutral

4

grupos: positivo, negativo, ambíguo, neutro

Exemplos — um texto pode carregar várias emoções

rótulos de ouro

“Thank you so much, this really helped!”

gratitude · admiration

“I can't believe they cancelled it again.”

disappointment · annoyance

“Wait... what does that even mean?”

confusion · curiosity

Multirrótulo $\neq$ multiclasse: por isso sigmoide + limiar

Como o problema é modelado e por que o limiar importa

Multiclasse · softmax

USADO NESTE TRABALHO

Multirrótulo · sigmoide

Consequência: o limiar fixo de 0,5 é decisivo — emoções raras quase nunca ultrapassam o corte e ficam sem rótulo.

Mesma arquitetura, pré-treino mais robusto no RoBERTa

O que realmente muda entre os dois modelos

BERT · bert-base-uncased

RoBERTa · roberta-base

Mesma arquitetura Transformer (12 camadas, ~125M parâmetros). O que muda é como cada modelo foi pré-treinado.

Pipeline: dados → tokenização → fine-tuning → avaliação

Mesmo fluxo para os dois modelos — só o checkpoint pré-treinado muda



Comparação controlada: a única variável entre os experimentos é o modelo pré-treinado.

Comparação justa: hiperparâmetros idênticos

Trainer da Hugging Face em GPU NVIDIA T4 (Google Colab)

Hiperparâmetro	Valor
Learning rate	2e-5
Batch size	64
Épocas	até 5 (melhor: 3)
max_length	64 tokens
Precisão	FP16 (mista)
Seed	42
Seleção	F1 macro (val.)

Ambiente & ferramentas

Sob desbalanceamento, o F1 macro é a métrica decisiva

Quatro métricas, com foco na mais exigente

MÉTRICA PRINCIPAL

F1 macro

Média simples do F1 das 28 classes: cada emoção pesa igual, inclusive as raras. É a métrica mais exigente — e a mais honesta — sob forte desbalanceamento.

F1 micro

Agrega todas as decisões; dominado pelas classes frequentes.

F1 ponderado

F1 por classe, ponderado pela frequência de cada uma.


Subset accuracy

Fração de exemplos com o conjunto exato de rótulos acertado.

RoBERTa quase dobra o F1 macro do BERT

Resultados no conjunto de teste — RoBERTa vence em todas as métricas

Métricas no conjunto de teste — BERT vs RoBERTa



Ganho consistente: RoBERTa supera o BERT em F1 macro, micro, ponderado e subset accuracy.

RoBERTa cobre 17 classes; o BERT, apenas ~6

Número de emoções com F1 acima de zero no teste

BERT

≈ 6

classes com F1 > 0

gratitude · love · amusement · admiration · joy · neutral

RoBERTa

17

classes cobertas — quase 3× mais

+ anger · curiosity · disapproval · optimism · sadness ·
remorse · fear ...


Mas ambos ainda falham nas classes raras

Emoções pouco frequentes — grief, pride, relief, nervousness, embarrassment — recebem F1 ≈ 0 nos dois modelos. O desbalanceamento limita o teto de desempenho.


BERT colapsa; RoBERTa recupera negative e ambiguous

Confusão por grupo de sentimento (normalizada por linha)

BERT



RoBERTa




BERT nunca prevê negative nem ambiguous (colunas vazias). RoBERTa recupera negative ($F1 \approx 0,40$) e ambiguous ($F1 \approx 0,46$).


Matriz 28×28: diagonal mais forte no RoBERTa

Confusão ouro × predito por classe (normalizada por linha)

BERT



RoBERTa



O erro dominante é detecção perdida

Dois padrões explicam quase todos os erros do RoBERTa

1 Detecção perdida

erro mais frequente

- Limiar fixo de 0,5 é conservador nas classes raras.
- Nenhum logit passa do corte → exemplo fica sem rótulo previsto.
- Recall ≈ 0 nas raras derruba o F1 macro.

2 Confusões entre vizinhas

troca por emoções semanticamente próximas

pride → admiration **0,64**

relief → joy **0,67**

confusion → curiosity

disgust → amusement

Por que o RoBERTa vence — e onde ainda falha

Discussão dos resultados e limitações do estudo

Por que o RoBERTa vence

Limitações

O gargalo não é a capacidade do modelo, e sim o desbalanceamento das classes somado ao limiar fixo de decisão.

Conclusão e próximos passos

RoBERTa supera o BERT; o desafio que resta é o desbalanceamento

CONCLUSÃO

- RoBERTa supera o BERT: F1 macro quase 2× e 17 vs ~6 classes cobertas.
- Resposta à pergunta: sim — o pré-treino mais robusto rende ganhos reais aqui.
- Gargalo: desbalanceamento + limiar fixo, não o modelo.

TRABALHOS FUTUROS

- Ajuste de limiar por classe (em vez de 0,5 fixo).
- Focal loss e ponderação de classes no treino.
- Data augmentation para emoções raras.
- Mais épocas e modelos maiores (roberta-large).

Declaração de uso de IA generativa

Transparência sobre o uso de ferramentas de IA no trabalho

Ferramenta utilizada: Claude (Anthropic)

IA

- Geração e depuração de código do pipeline de treino e avaliação.
- Apoio à redação e à revisão do artigo e desta apresentação.
- Concepção, experimentos, números e análises conduzidos e verificados pelo autor.

O uso seguiu as diretrizes da disciplina; a responsabilidade final pelo conteúdo é do autor.

Obrigado!

Dúvidas e perguntas são bem-vindas.