

Classificação de Emoções de Granularidade Fina com Transformers: BERT e RoBERTa no Corpus GoEmotions

Gustavo Auad Piccoli¹

¹Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)

Caixa Postal 15.064 – 91.501-970 – Porto Alegre – RS – Brasil

gapiccoli@inf.ufrgs.br

Abstract. *This work investigates fine-grained emotion classification of Reddit comments using the GoEmotions corpus, which contains about 58,000 texts annotated over 28 categories (27 emotions plus a neutral class). We frame the task as multi-label classification, since each comment may express several emotions at once. We fine-tune two Transformer-based models — BERT (bert-base-uncased), used as a baseline, and RoBERTa (roberta-base), as the main model — under identical hyperparameters, and compare them using macro, micro and weighted F1, as well as subset accuracy. RoBERTa nearly doubles BERT's macro F1 (0.264 vs. 0.137 on the test set) and covers far more emotion classes, although both models struggle with low-frequency emotions. We also provide a per-class and per-sentiment-group analysis that highlights the main error patterns.*

Resumo. *Este trabalho investiga a classificação de emoções de granularidade fina em comentários do Reddit utilizando o corpus GoEmotions, que reúne cerca de 58 mil textos anotados em 28 categorias (27 emoções e a classe neutra). A tarefa é tratada como classificação multirrotulo, em que cada comentário pode expressar simultaneamente mais de uma emoção. Realizamos o ajuste fino (fine-tuning) de dois modelos baseados em Transformers — BERT (bert-base-uncased), adotado como baseline, e RoBERTa (roberta-base), como modelo principal — sob hiperparâmetros idênticos, e os comparamos por meio de F1 macro, micro e ponderado, além da acurácia de subconjunto. O RoBERTa praticamente dobra o F1 macro do BERT (0,264 contra 0,137 no conjunto de teste) e cobre um número muito maior de classes, embora ambos os modelos enfrentem dificuldades nas emoções de baixa frequência. Apresentamos ainda uma análise por classe e por grupo de sentimento que evidencia os principais padrões de erro.*

1. Introdução

A análise de sentimentos é uma das tarefas mais consolidadas do Processamento de Linguagem Natural (PLN), com aplicações que vão da mineração de opinião em redes sociais ao monitoramento de marcas e à mediação de diálogos automatizados. Tradicionalmente, o problema é formulado como uma classificação de polaridade — positivo, negativo ou neutro —, o que, embora útil, descarta grande parte da riqueza afetiva presente na linguagem humana. Reações como gratidão, decepção, curiosidade ou

alívio carregam nuances que a polaridade isolada não captura, e que são justamente as mais relevantes para compreender a intenção e o estado emocional de quem escreve.

Nesse contexto, a classificação de emoções de granularidade fina busca atribuir a um texto categorias afetivas específicas, em vez de apenas um sinal de polaridade. O corpus GoEmotions [Demszky et al. 2020] é hoje uma das principais referências para essa tarefa: reúne cerca de 58 mil comentários reais do Reddit, anotados manualmente segundo uma taxonomia de 28 categorias — 27 emoções e uma classe neutra. Uma característica central do corpus é seu caráter multirrótulo: um mesmo comentário pode expressar mais de uma emoção simultaneamente (aproximadamente 16% dos exemplos possuem mais de um rótulo), o que aproxima a tarefa do uso real da linguagem e, ao mesmo tempo, a torna mais difícil do que a classificação de rótulo único.

Os modelos baseados na arquitetura Transformer [Vaswani et al. 2017] redefiniram o estado da arte em praticamente todas as tarefas de PLN. Modelos de linguagem pré-treinados como o BERT [Devlin et al. 2019] e sua variante otimizada RoBERTa [Liu et al. 2019] aprendem representações contextuais profundas a partir de grandes volumes de texto não rotulado e, em seguida, podem ser ajustados (fine-tuning) para tarefas específicas a um custo relativamente baixo. A questão prática que motiva este trabalho é até que ponto as melhorias introduzidas no pré-treinamento se traduzem em ganhos concretos em uma tarefa difícil e desbalanceada como a classificação multirrótulo de emoções de granularidade fina.

Este trabalho compara, sob condições idênticas, dois modelos Transformer no corpus GoEmotions: o BERT (bert-base-uncased), adotado como baseline por ser o mesmo modelo utilizado no artigo original do dataset, e o RoBERTa (roberta-base), adotado como modelo principal. Ambos são ajustados com a mesma configuração de hiperparâmetros, a mesma função de perda e o mesmo protocolo de avaliação, de modo que as diferenças observadas possam ser atribuídas à qualidade do pré-treinamento e da tokenização, e não a escolhas de ajuste. Além da comparação agregada, a principal contribuição está na análise detalhada do comportamento dos modelos: desempenho por classe, padrões de coativação entre emoções e uma matriz de confusão em nível de grupo de sentimento, que tornam explícitos os principais modos de erro.

O restante do artigo está organizado da seguinte forma. A Seção 2 apresenta o referencial teórico sobre modelos Transformer e classificação multirrótulo. A Seção 3 discute trabalhos relacionados. A Seção 4 descreve a metodologia, incluindo o corpus, os modelos, a configuração de treinamento e as métricas. A Seção 5 apresenta e discute os resultados experimentais. A Seção 6 declara o uso de inteligência artificial generativa na elaboração do trabalho, e a Seção 7 conclui o artigo e aponta direções futuras.

2. Referencial Teórico

2.1. Modelos de Linguagem baseados em Transformers

A arquitetura Transformer [Vaswani et al. 2017] substituiu as redes recorrentes por um mecanismo de autoatenção (self-attention) que permite modelar dependências entre quaisquer posições de uma sequência em paralelo, sem a propagação sequencial dos estados ocultos. Esse mecanismo, combinado a camadas de atenção multi-cabeça e a codificações posicionais, viabilizou o treinamento eficiente de modelos profundos sobre grandes corpora. Sobre essa base surgiram os modelos de linguagem pré-treinados, que

aprendem representações de propósito geral em uma etapa de pré-treinamento auto-supervisionado e são posteriormente especializados por meio de fine-tuning.

O paradigma de pré-treinamento seguido de ajuste fino tornou-se dominante porque dissocia o aprendizado linguístico de propósito geral — caro e feito uma única vez — do aprendizado específico da tarefa, que passa a exigir poucos dados rotulados e poucas épocas de treinamento. Na prática, adiciona-se ao modelo pré-treinado uma camada de classificação e reotimizam-se os pesos para a tarefa-alvo, aproveitando o conhecimento linguístico já codificado nas representações contextuais.

2.2. BERT e RoBERTa

O BERT (Bidirectional Encoder Representations from Transformers) [Devlin et al. 2019] é um codificador Transformer pré-treinado de forma bidirecional por meio de duas tarefas: a modelagem de linguagem mascarada (Masked Language Modeling), que prevê tokens ocultos a partir de seu contexto à esquerda e à direita, e a predição da próxima sentença (Next Sentence Prediction, NSP). A representação contextual do token especial [CLS] é tradicionalmente utilizada como vetor agregado da sequência para tarefas de classificação. Neste trabalho, o BERT cumpre o papel de baseline por ser exatamente o modelo empregado no artigo original do GoEmotions.

O RoBERTa (Robustly Optimized BERT Approach) [Liu et al. 2019] mantém a mesma arquitetura do BERT, mas revisa criticamente seu protocolo de pré-treinamento. As principais mudanças incluem treinar com muito mais dados e por mais tempo, usar lotes maiores, remover a tarefa de NSP — considerada pouco útil —, aplicar mascaramento dinâmico e adotar uma tokenização por Byte-Pair Encoding (BPE) em nível de bytes. Essas alterações, embora não modifiquem a arquitetura, produzem representações consistentemente melhores em diversas tarefas, o que faz do RoBERTa uma escolha natural para o modelo principal desta comparação.

2.3. Classificação Multirrótulo

Na classificação de rótulo único (multiclasse), cada exemplo pertence a exatamente uma classe e o modelo é tipicamente treinado com uma função softmax sobre as classes e perda de entropia cruzada. Já na classificação multirrótulo, cada exemplo pode pertencer simultaneamente a zero, uma ou várias classes. Isso é modelado tratando cada classe como um problema de decisão binário independente: aplica-se uma função sigmoide a cada logit de saída e otimiza-se a perda de entropia cruzada binária (Binary Cross-Entropy). Em inferência, atribui-se cada rótulo cuja probabilidade ultrapasse um limiar de decisão, usualmente 0,5.

Essa formulação é a adequada para o GoEmotions, em que uma parcela relevante dos comentários expressa mais de uma emoção. Adotar uma formulação multiclasse, que força um único rótulo por exemplo, descartaria essas coocorrências e distorceria tanto o treinamento quanto a avaliação. Por esse motivo, todo o trabalho assume a tarefa como multirrótulo sobre as 28 categorias do corpus.

3. Trabalhos Relacionados

A modelagem computacional de emoções possui longa tradição em PLN. Boa parte dos primeiros trabalhos apoiava-se em modelos psicológicos discretos, como as seis emoções básicas de Ekman (alegria, tristeza, raiva, medo, surpresa e nojo), e em léxicos afetivos

que associam palavras a categorias emocionais. Embora interpretáveis, abordagens baseadas em léxico têm dificuldade em lidar com contexto, negação, ironia e com a sobreposição de emoções em um mesmo enunciado.

O GoEmotions [Demszky et al. 2020] representa um avanço importante ao oferecer uma taxonomia mais fina, de 27 emoções e uma classe neutra, anotada manualmente sobre um grande volume de comentários do Reddit. No artigo original, os autores ajustam um modelo BERT e relatam um F1 macro da ordem de 0,46 sobre o conjunto de teste, estabelecendo uma referência para a tarefa. Os autores também propõem um agrupamento das emoções em quatro grandes categorias de sentimento — positivo, negativo, ambíguo e neutro —, útil para analisar erros em um nível mais agregado, estratégia que também adotamos neste trabalho.

Desde então, a literatura de classificação de emoções tem explorado modelos pré-treinados cada vez mais robustos. Variantes como o RoBERTa [Liu et al. 2019] frequentemente superam o BERT [Devlin et al. 2019] em tarefas de classificação de texto, graças a um pré-treinamento mais extenso e a uma tokenização por sub-palavras em nível de bytes. Trabalhos sobre classificação multirrótulo de emoções destacam ainda que o forte desbalanceamento entre classes — comum quando algumas emoções são muito mais frequentes que outras — degrada especialmente o F1 macro, e que técnicas como ajuste de limiar por classe, reponderação da perda e aumento de dados podem mitigar parcialmente esse efeito.

Especificamente sobre o GoEmotions, trabalhos posteriores ao artigo original investigaram desde arquiteturas alternativas baseadas em Transformers até estratégias de tratamento do desbalanceamento e de transferência para outros domínios e idiomas, confirmando que a tarefa permanece desafiadora sobretudo nas emoções menos frequentes. De modo mais amplo, campanhas de avaliação como o SemEval têm impulsionado a pesquisa em detecção de emoções e de afeto em textos curtos, consolidando o F1 — em suas variantes macro e micro — como métrica padrão para tarefas multirrótulo nesse domínio. Esse histórico reforça duas escolhas metodológicas deste trabalho: o uso do F1 macro como métrica principal e a ênfase na análise por classe, e não apenas em um número agregado.

Em relação a esse panorama, o presente trabalho não propõe um novo modelo, mas oferece uma comparação controlada entre BERT e RoBERTa sobre o GoEmotions, mantendo todos os demais fatores fixos, e a acompanha de uma análise de erros por classe e por grupo de sentimento. O objetivo é isolar e quantificar o efeito do pré-treinamento, além de evidenciar concretamente onde os modelos falham — informação frequentemente ausente quando apenas métricas agregadas são reportadas.

4. Metodologia

4.1. Corpus GoEmotions

Utilizamos a configuração *simplified* do GoEmotions, disponível no Hugging Face Hub ([google-research-datasets/go_emotions](https://huggingface.co/google-research-datasets/go_emotions)), já dividida em conjuntos de treino, validação e teste (aproximadamente 43,4 mil, 5,4 mil e 5,4 mil exemplos, respectivamente). Cada comentário é representado por seus rótulos de emoção, e a taxonomia das 28 categorias é validada em tempo de execução contra os nomes fornecidos pelo Hub, garantindo a ordem canônica das classes. Os rótulos são convertidos para um vetor multi-hot de 28 dimensões,

em que cada posição indica a presença (1) ou ausência (0) da emoção correspondente, permitindo representar múltiplas emoções por exemplo.

Para a análise de erros, adotamos o agrupamento das 28 categorias em quatro grupos de sentimento proposto por [Demszky et al. 2020]: positivo (12 emoções), negativo (11 emoções), ambíguo (4 emoções: confusion, curiosity, realization e surprise) e neutro (a classe neutral). Esse agrupamento permite avaliar se os erros do modelo ocorrem entre emoções de polaridade semelhante — confusões mais brandas — ou entre polaridades opostas.

4.2. Modelos e Formulação da Tarefa

Ambos os modelos são instanciados a partir de checkpoints pré-treinados — bert-base-uncased e roberta-base — acrescidos de uma cabeça de classificação linear com 28 saídas. A tarefa é configurada explicitamente como classificação multirrotulo (`problem_type="multi_label_classification"`), o que faz com que a função de perda seja a entropia cruzada binária com logits (`BCEWithLogitsLoss`): cada uma das 28 saídas é tratada como um classificador binário independente, com sua própria sigmoide. Não há, portanto, competição softmax entre as classes, o que é coerente com a possibilidade de coocorrência de emoções.

A tokenização é feita pelo tokenizador nativo de cada modelo (WordPiece para o BERT e BPE em nível de bytes para o RoBERTa), com truncamento e preenchimento dinâmico por lote. Como os comentários do Reddit são curtos, fixamos o comprimento máximo em 64 tokens, valor que cobre a grande maioria dos exemplos sem desperdício computacional.

4.3. Configuração de Treinamento

O treinamento é conduzido com a API Trainer da biblioteca Transformers. Para garantir uma comparação justa, BERT e RoBERTa compartilham exatamente os mesmos hiperparâmetros, resumidos na Tabela 1. Ao final de cada época o modelo é avaliado na validação, e o melhor checkpoint é selecionado pelo maior F1 macro (`metric_for_best_model="macro_f1"`, com `load_best_model_at_end`). Embora o limite tenha sido fixado em cinco épocas, o melhor checkpoint de ambos os modelos ocorreu na terceira época, indício de estabilização precoce do desempenho na validação.

Tabela 1. Hiperparâmetros de treinamento, idênticos para BERT e RoBERTa.

Hiperparâmetro	Valor
Taxa de aprendizado	2×10^{-5}
Tamanho do lote	64
Número máximo de épocas	5
Decaimento de pesos (weight decay)	0,01
Proporção de warmup	0,1
Comprimento máximo de sequência	64 tokens

Precisão numérica	fp16 (mista)
Limiar de decisão	0,5
Semente aleatória	42
Seleção do melhor modelo	maior F1 macro (validação)

4.4. Métricas de Avaliação

Com 28 classes fortemente desbalanceadas, a acurácia isolada é pouco informativa. Por isso, a avaliação combina quatro métricas, todas calculadas após a aplicação da sigmoide e do limiar de 0,5 sobre os logits. O F1 macro é a métrica principal: corresponde à média simples do F1 de cada classe e, por tratar todas as classes igualmente, é especialmente sensível ao desempenho nas emoções raras — exatamente o aspecto mais desafiador da tarefa. O F1 micro agrega verdadeiros positivos, falsos positivos e falsos negativos globalmente e é reportado por ser a métrica usada no artigo original, permitindo comparação. O F1 ponderado pondera o F1 de cada classe pelo seu suporte, oferecendo uma visão intermediária. Por fim, a acurácia de subconjunto (subset accuracy) mede a fração de exemplos em que o conjunto de rótulos previstos coincide exatamente com o conjunto de referência, sendo a métrica mais rigorosa, pois um único rótulo divergente já invalida o exemplo.

4.5. Ferramentas e Ambiente Experimental

A implementação foi desenvolvida em Python, tendo como base o ecossistema PyTorch e a biblioteca Hugging Face Transformers [Wolf et al. 2020], da qual foram utilizados os componentes de modelagem (AutoModelForSequenceClassification e AutoTokenizer) e, sobretudo, a classe Trainer, responsável pelo laço de treinamento, pela avaliação periódica ao final de cada época e pela seleção automática do melhor checkpoint segundo o F1 macro de validação. O carregamento e o pré-processamento do GoEmotions foram realizados com a biblioteca Hugging Face Datasets, enquanto as métricas de avaliação foram calculadas com o scikit-learn [Pedregosa et al. 2011]. Operações auxiliares de manipulação de dados utilizaram NumPy e Pandas.

Os experimentos foram conduzidos majoritariamente em uma GPU NVIDIA T4 disponibilizada pelo ambiente Google Colab, com treinamento em precisão mista (fp16) para reduzir o consumo de memória e acelerar o processamento; o desenvolvimento e a validação iniciais do pipeline foram realizados localmente em uma GPU NVIDIA GTX 1650 de 4 GB. Para favorecer a reprodutibilidade, fixou-se a semente aleatória em 42 e mantiveram-se versões controladas das dependências. É importante ressaltar que os mesmos scripts e arquivos de configuração foram empregados para o BERT e o RoBERTa, alterando-se apenas o identificador do modelo pré-treinado, o que assegura uma comparação justa entre as duas arquiteturas.

5. Experimentos e Resultados

Esta seção apresenta os resultados do ajuste fino de BERT e RoBERTa sobre o GoEmotions, sempre reportados no conjunto de teste, salvo indicação contrária.

Discutimos primeiro as métricas agregadas, depois o desempenho por classe e, por fim, os padrões de erro em nível de grupo de sentimento.

5.1. Resultados Gerais

A Tabela 2 resume as quatro métricas no conjunto de teste para os dois modelos. O RoBERTa supera o BERT em todas as métricas, com destaque para o F1 macro, em que praticamente dobra o desempenho do baseline (0,264 contra 0,137). O ganho é expressivo também no F1 micro (0,522 contra 0,452), no F1 ponderado (0,458 contra 0,346) e na acurácia de subconjunto (0,387 contra 0,315). Como BERT e RoBERTa foram treinados com hiperparâmetros idênticos, essa diferença é atribuível sobretudo à qualidade do pré-treinamento e da tokenização do RoBERTa. Os valores de validação acompanham de perto os de teste (F1 macro de 0,135 e 0,262, respectivamente), sem sinais de sobreajuste.

Tabela 2. Métricas no conjunto de teste (limiar 0,5). Melhores valores em negrito.

Métrica	BERT	RoBERTa
F1 macro	0,137	0,264
F1 micro	0,452	0,522
F1 ponderado	0,346	0,458
Acurácia de subconjunto	0,315	0,387

5.2. Desempenho por Classe

A análise por classe revela que as métricas agregadas escondem comportamentos muito distintos. O BERT obtém F1 maior que zero em apenas 6 das 28 classes — gratitude, love, amusement, admiration, neutral e, de forma residual, optimism (F1 de 0,011, com precisão alta mas recall quase nulo). Nas demais 22 classes, o modelo simplesmente não emite predições positivas, resultando em F1 igual a zero. Em outras palavras, o baseline colapsa nas emoções mais frequentes e na classe neutra, ignorando o restante da taxonomia.

O RoBERTa amplia substancialmente a cobertura: obtém F1 positivo em 17 das 28 classes, recuperando emoções de frequência intermediária como joy (0,549), optimism (0,535), sadness (0,480), surprise (0,390), approval (0,345), curiosity (0,308), anger (0,296) e disapproval (0,276). A Tabela 3 apresenta o F1 por classe para um conjunto representativo de emoções, ordenado pelo desempenho do RoBERTa. Note-se que, nas classes de cabeça (gratitude, love, amusement, admiration e neutral), os dois modelos têm desempenho praticamente equivalente; toda a vantagem do RoBERTa vem das classes de frequência média, que o BERT não consegue aprender.

Tabela 3. F1 por classe no conjunto de teste para classes selecionadas, ordenadas pelo F1 do RoBERTa. “Sup.” indica o suporte (número de exemplos de teste).

Emoção	Sup.	BERT	RoBERTa
gratitude	352	0,919	0,915
amusement	264	0,810	0,826

love	238	0,813	0,808
admiration	504	0,669	0,698
neutral	1787	0,627	0,627
joy	161	0,000	0,549
optimism	186	0,011	0,535
sadness	156	0,000	0,480
surprise	141	0,000	0,390
approval	351	0,000	0,345
curiosity	284	0,000	0,308
anger	198	0,000	0,296
disapproval	267	0,000	0,276
confusion	153	0,000	0,173

É importante destacar que ambos os modelos falham completamente nas emoções mais raras. Classes como grief (6 exemplos de teste), relief (11), pride (16), nervousness (23) e embarrassment (37) têm F1 igual a zero nos dois modelos. Esse padrão evidencia o principal limite da abordagem: sob forte desbalanceamento e com um limiar de decisão fixo em 0,5, as classes de baixa frequência praticamente não são previstas, o que penaliza diretamente o F1 macro.

5.3. Análise por Grupo de Sentimento

Para entender melhor a natureza dos erros, agregamos as 28 categorias nos quatro grupos de sentimento (positivo, negativo, ambíguo e neutro) e calculamos, para cada grupo verdadeiro, a distribuição dos grupos previstos. No caso do BERT, o resultado é eloquente: o modelo nunca atribui os grupos negativo ou ambíguo — essas colunas são integralmente nulas (Figura 1, à esquerda). Exemplos verdadeiramente negativos são classificados como positivos (28%) ou, na maioria, como neutros (72%); exemplos ambíguos vão para positivo (39%) ou neutro (61%). Ou seja, o BERT reduz, na prática, todo o espectro afetivo a um eixo positivo–neutro.

O RoBERTa, por sua vez, recupera os grupos negativo e ambíguo, como mostram a Tabela 4 e a Figura 1 (à direita). A diagonal principal passa a ser dominante para positivo (0,887) e neutro (0,836) e torna-se majoritária também para negativo (0,404) e ambíguo (0,463), ainda que com confusão relevante com a classe neutra. Esse comportamento é consistente com o ganho de F1 macro observado na Seção 5.1: ao deixar de colapsar emoções negativas e ambíguas em neutro, o RoBERTa distribui melhor suas previsões pelo espaço de classes.

Tabela 4. Matriz de confusão por grupo de sentimento do RoBERTa (linhas normalizadas; cada linha é um grupo verdadeiro e soma 1). Diagonal em negrito.

Verdadeiro	Positivo	Negativo	Ambíguo	Neutro
------------	----------	----------	---------	--------

Positivo	0,887	0,007	0,012	0,094
Negativo	0,199	0,404	0,034	0,363
Ambíguo	0,251	0,028	0,463	0,258
Neutro	0,111	0,025	0,028	0,836

Além das matrizes de grupo de sentimento, o pipeline de avaliação gera uma matriz de confusão por classe (28×28, ouro versus predito), apresentada na Seção 5.5, e uma análise qualitativa de exemplos classificados incorretamente. Já se observa que grande parte das confusões ocorre entre emoções semanticamente próximas dentro de um mesmo grupo de sentimento, o que indica que os erros remanescentes do RoBERTa são, em sua maioria, de granularidade fina, e não inversões de polaridade.

5.4. Discussão

Os resultados confirmam, de forma controlada, a vantagem do RoBERTa sobre o BERT na classificação multirrótulo de emoções de granularidade fina: mantidos fixos arquitetura de cabeça, função de perda, hiperparâmetros e protocolo de avaliação, o RoBERTa praticamente dobra o F1 macro. A explicação mais plausível está no pré-treinamento mais extenso e na tokenização por BPE em nível de bytes, que produzem representações mais úteis para distinguir emoções de frequência intermediária.

Ao mesmo tempo, os valores absolutos de F1 macro (0,264 para o RoBERTa) ficam abaixo do reportado no artigo original do GoEmotions (em torno de 0,46 com BERT). Parte dessa diferença decorre de escolhas deliberadas de simplicidade adotadas aqui: utilizamos um único limiar de decisão fixo (0,5) para todas as classes, em vez de calibrar um limiar por classe, e o melhor checkpoint foi atingido já na terceira época. Como o F1 macro é extremamente sensível às classes raras — que, sob limiar fixo, raramente ultrapassam o ponto de corte —, essas decisões penalizam justamente a métrica principal. Isso aponta caminhos claros de melhoria, discutidos na conclusão.

Por fim, a análise por classe e por grupo de sentimento mostra que o gargalo não está nas emoções frequentes — bem resolvidas por ambos os modelos — mas na cauda longa da distribuição. O desbalanceamento severo do GoEmotions, em que poucas classes concentram a maior parte dos exemplos, é o fator que mais limita o desempenho agregado.

Casos especialmente difíceis envolvem ironia e sarcasmo, comentários muito curtos, uso de emojis e exemplos genuinamente multirrótulo, nos quais o modelo acerta apenas parte das emoções esperadas. Esses resultados sugerem que ganhos adicionais dependem menos da capacidade bruta do modelo e mais de estratégias direcionadas ao desbalanceamento e à calibração do limiar de decisão, discutidas na conclusão.

5.5. Análise Qualitativa de Erros

Para além das métricas agregadas, inspecionamos individualmente os erros cometidos pelo RoBERTa no conjunto de teste, a fim de compreender seus modos de falha. Dois padrões se destacam. O primeiro, e mais frequente, é a detecção perdida: para muitos exemplos o modelo não atribui nenhum rótulo, pois todas as probabilidades produzidas

pela sigmoide ficam abaixo do limiar de 0,5. Esse comportamento conservador concentra-se justamente nas emoções de baixa e média frequência, evidenciando a interação entre o desbalanceamento do corpus e a escolha de um limiar fixo e global.

O segundo padrão é a confusão entre emoções semanticamente vizinhas. A matriz de confusão por classe (Figura 2) revela que parcelas expressivas de certas emoções são previstas como categorias próximas: pride é majoritariamente classificada como admiration (0,64), relief como joy (0,67), confusion como curiosity (0,27), disgust como amusement (0,35) e excitement como admiration (0,25), enquanto approval migra em grande parte para neutral (0,31). Tais confusões não são arbitrárias: refletem a própria ambiguidade da taxonomia de granularidade fina, em que fronteiras entre emoções correlatas são tênues mesmo para anotadores humanos.

Tabela 5. Exemplos reais de erros do RoBERTa no conjunto de teste, ilustrando confusões entre emoções adjacentes e detecções perdidas sob o limiar de 0,5.

Comentário (Reddit)	Verdadeiro	Predição	Tipo de erro
“Kings fan here, good luck to you guys!”	excitement	optimism	confusão entre positivas adjacentes
“100%! Congrats on your job too!”	gratitude	admiration	confusão entre positivas adjacentes
“thats amazing!! Congrats!”	admiration, joy	admiration	rótulo perdido (joy)
“I’m sorry to hear that friend :(”	remorse	(nenhum)	detecção perdida
“That was an incredibly dumb thing to do.”	annoyance, disapproval, disgust	(nenhum)	detecção perdida (multirrótulo)

6. Declaração de Uso de Inteligência Artificial Generativa

Em conformidade com as exigências do trabalho, declara-se o uso de ferramentas de inteligência artificial generativa em sua elaboração. A ferramenta Claude (Anthropic) foi utilizada como assistente de programação na construção do código do projeto — estruturação do pipeline de dados, scripts de treinamento e avaliação, e organização do repositório — e como apoio à redação e revisão textual deste artigo, incluindo a organização das seções e o aprimoramento da clareza do texto. Todas as decisões metodológicas, a definição dos experimentos, a interpretação dos resultados e a revisão final do conteúdo foram realizadas e validadas pelo autor, que se responsabiliza integralmente pelo trabalho. Os dados, as métricas e os resultados reportados foram gerados pela execução efetiva do código sobre o corpus GoEmotions, sem qualquer fabricação por parte das ferramentas de IA.

7. Conclusão

Este trabalho comparou, sob condições idênticas, os modelos BERT e RoBERTa na tarefa de classificação multirrótulo de emoções de granularidade fina sobre o corpus GoEmotions, com 28 categorias. O RoBERTa superou o BERT em todas as métricas, praticamente dobrando o F1 macro (0,264 contra 0,137 no teste) e ampliando de 6 para 17 o número de classes efetivamente aprendidas. A análise por grupo de sentimento

mostrou que o baseline colapsa o espectro afetivo em um eixo positivo–neutro, enquanto o RoBERTa recupera os grupos negativo e ambíguo, cometendo erros majoritariamente entre emoções semanticamente próximas.

A principal limitação identificada é o desempenho nas emoções raras, fortemente penalizado pelo desbalanceamento do corpus e pelo uso de um limiar de decisão fixo. Como trabalhos futuros, destacam-se: (i) a calibração de um limiar de decisão por classe sobre o conjunto de validação; (ii) o uso de funções de perda sensíveis ao desbalanceamento, como reponderação por classe ou focal loss; (iii) técnicas de aumento de dados para as classes minoritárias; e (iv) a avaliação de modelos maiores ou pré-treinados em domínio, bem como treinamentos mais longos. Tais direções têm potencial para elevar especialmente o F1 macro, aproximando os resultados dos relatados na literatura.

Referências

- Demszky, D., Movshovitz-Attias, D., Ko, J., Cowen, A., Nemade, G. and Ravi, S. (2020) “GoEmotions: A Dataset of Fine-Grained Emotions”, In: Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL), p. 4040–4054.
- Devlin, J., Chang, M.-W., Lee, K. and Toutanova, K. (2019) “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, In: Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT), p. 4171–4186.
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L. and Stoyanov, V. (2019) “RoBERTa: A Robustly Optimized BERT Pretraining Approach”, arXiv:1907.11692.
- Pedregosa, F. et al. (2011) “Scikit-learn: Machine Learning in Python”, Journal of Machine Learning Research, v. 12, p. 2825–2830.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. and Polosukhin, I. (2017) “Attention Is All You Need”, In: Advances in Neural Information Processing Systems 30 (NeurIPS).
- Wolf, T. et al. (2020) “Transformers: State-of-the-Art Natural Language Processing”, In: Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP): System Demonstrations, p. 38–45.

Anexo A. Figuras

Esta seção reúne as figuras geradas pela rotina de avaliação, referenciadas ao longo da Seção 5.




Figura 1. Matrizes de confusão por grupo de sentimento (normalizadas por linha) para o BERT (à esquerda) e o RoBERTa (à direita). No BERT, as colunas negative e ambiguous são praticamente nulas — o modelo colapsa para as classes positive e neutral — ao passo que o RoBERTa recupera as diagonais negative e ambiguous.





Figura 2. Matrizes de confusão por classe (28x28, normalizadas por linha) para o BERT (acima) e o RoBERTa (abaixo). No BERT, as previsões concentram-se em poucas colunas (admiration, amusement, gratitude, love e neutral); o RoBERTa exibe uma diagonal muito mais rica, ativando emoções como anger, confusion, curiosity, disapproval, sadness e surprise, embora persistam confusões com classes vizinhas e com a classe neutral.